



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY



FACULTAD DE
INGENIERÍA
UDELAR

Introducción a la Ciencia de Datos
Maestría en Ciencia de Datos y Aprendizaje Automático

Tarea 1: Exploración y Limpieza de Datos de Noticias

Integrantes
CASTROMAN, Nicole
ROMERO, Valeria

14 de Mayo de 2026

Índice

1. Cargado y Limpieza de Datos	2
1.1. Exploración de Datos	2
1.2. Visualización Temporal	4
1.3. Limpieza de Texto	5
1.4. Elección de Campos de Texto	5
1.5. Indicios que Identifican al Medio de Prensa	6
1.6. Restricción por Sección o Período Temporal	7
2. Conteo de Palabras y Visualizaciones	8
2.1. Palabras más Frecuentes por Medio	8
2.2. Medios con Mayor Cantidad de Palabras	10
2.3. Matriz de Menciones entre Medios	11
2.4. Preguntas Propuestas	13
3. Conclusiones	14

Introducción

En esta tarea se trabaja con un subconjunto del dataset *All The News 2.1*¹, que contiene artículos de noticias publicados en distintos medios de prensa anglosajones. El objetivo es explorar y limpiar los datos, así como plantear preguntas para un trabajo posterior.

El dataset utilizado contiene **30.213** filas y **12** columnas: `idx`, `article_idx`, `date`, `year`, `month`, `day`, `author`, `title`, `article`, `url`, `section` y `publication`.

El código fuente de este trabajo está disponible en <https://github.com/vromero98/Tarea-1-IntroCD>.

1. Cargado y Limpieza de Datos

1.1. Exploración de Datos

Datos faltantes

Se analizó la presencia de valores nulos en cada columna. Los resultados se resumen en la Tabla 1.

Tabla 1: Datos faltantes por columna

Columna	Faltantes	Porcentaje (%)
<code>author</code>	11.405	37,7
<code>section</code>	10.232	33,9
<code>article</code>	1.176	3,9
<code>url</code>	141	0,5
<code>publication</code>	141	0,5

El resto de las columnas no tiene datos faltantes.




Figura 1: Matriz de nulidad.

¹Versión original disponible en <https://huggingface.co/datasets/rjac/all-the-news-2-1-Component-one>. En este trabajo se utilizó un muestreo provisto por la cátedra, disponible en <https://huggingface.co/datasets/tomas-gr/all-the-news-2-1-Component-one-sampled>.

Se generó un informe de data profiling con `ydata-profiling`, que permite explorar distribuciones, correlaciones y valores faltantes de forma interactiva. La Figura 1 muestra la matriz de nulidad del dataset completo: los 141 registros sin `url` coinciden exactamente con los que no tienen `publication`, `article` ni `author`, por lo que corresponden a filas completamente vacías de contenido útil.

Distribución por medio de prensa

La Tabla 2 muestra la cantidad de artículos por publicación. Se observa un fuerte desbalance: Reuters representa el 31,2 % de todo el dataset, mientras que los medios menores tienen menos del 5 %.

Tabla 2: Artículos por medio de prensa (top 10)

Publicación	Artículos	Porcentaje (%)
Reuters	9.431	31,2
The New York Times	2.840	9,4
CNBC	2.623	8,7
The Hill	2.349	7,8
People	1.528	5,1
CNN	1.446	4,8
Refinery 29	1.236	4,1
Vice	1.154	3,8
Mashable	1.045	3,5
Business Insider	660	2,2
Otros	5.901	19,5

A partir de este punto se trabaja únicamente con los **cinco medios con mayor cantidad de artículos**: Reuters, The New York Times, CNBC, The Hill y People. El subconjunto resultante contiene **18.771 artículos**. El subconjunto de los cinco medios se obtuvo agrupando por `publication` y contando artículos no nulos en la columna `article`, lo que excluye los registros sin cuerpo de texto.




Figura 2: Distribución de artículos por medio de prensa en el subconjunto top 5.

1.2. Visualización Temporal

La columna `date` presenta formatos mixtos: algunos registros contienen únicamente la fecha (YYYY-MM-DD) mientras que otros incluyen marca de tiempo completa (YYYY-MM-DD HH:MM:SS). Se utilizó `pd.to_datetime` con `format='mixed'` para parsear ambos formatos de manera uniforme y `errors='raise'` para levantar error en caso de haber; ningún registro resultó con fecha inválida tras este proceso.

El rango temporal del dataset abarca desde 2016 hasta comienzos de 2020. Se puede observar la cantidad de artículos publicados por mes por medio de prensa en la Figura 3.




Figura 3: Cantidad de artículos publicados por mes para cada uno de los cinco medios seleccionados.

Patrones observados

- **Reuters** domina en volumen durante todo el período, con una caída notable entre mediados de 2018 y mediados de 2019, seguida de un repunte pronunciado hacia el final del periodo de tiempo.
- **The New York Times** mantiene un flujo estable y significativamente menor al de Reuters, aunque con una disminución gradual entre 2016 y 2017.
- **CNBC** mantiene un volumen estable desde 2016 hasta comienzos de 2019, momento en que registra un crecimiento antes de estabilizarse en un nivel algo mayor.
- **The Hill** presenta un volumen relativamente estable y uniforme a lo largo de todo el período.
- **People** presenta el volumen mensual más bajo y relativamente uniforme. Deja de tener datos a partir de enero de 2020, mientras que el resto de los medios sí mantienen cobertura durante ese intervalo.

1.3. Limpieza de Texto

Se implementó la función `clean_text` a partir del template provisto. Las transformaciones aplicadas, en orden, son:

1. **Eliminación de la primera línea del texto:** la expresión regular `^[^\n]*\n` elimina todo el contenido desde el inicio hasta el primer salto de línea inclusive. En muchos artículos esta primera línea corresponde al dateline o encabezado editorial. Sin embargo, cuando el dateline aparece en la misma línea que el cuerpo del artículo, este paso no produce cambios.
2. **Conversión a minúsculas:** normaliza el vocabulario para tratar variantes como “Reuters” y “reuters” como el mismo token.
3. **Normalización de apóstrofes:** las variantes tipográficas de apóstrofes (’, ‘, ‘) se reemplazan por el apóstrofe ASCII estándar (’).
4. **Eliminación de puntuación conservando apóstrofes:** la expresión regular `[^\w\s’]` reemplaza por espacios todos los caracteres que no sean alfanuméricos, espacios en blanco o apóstrofes. Esto preserva contracciones del inglés como “it’s” o “don’t” como un único token.
5. **Eliminación de secuencias numéricas:** la expresión regular `\d+` elimina cualquier secuencia de dígitos presente en el texto, incluyendo años, cantidades y números embebidos dentro de tokens alfanuméricos.
6. **Colapso de espacios múltiples:** la expresión regular `\s+` reemplaza secuencias repetidas de espacios en blanco por un único espacio.
7. **Eliminación de espacios iniciales y finales** mediante `str.strip()`.

Texto original (fragmento)	Texto limpio (fragmento)
<i>Feb 2 (Reuters) - Teva Pharmaceutical Industries Ltd : * EUROPEAN MEDICINES AGENCY (EMA) ACCEPTS FREMANEZUMAB MARKETING...</i>	<i>feb reuters teva pharmaceutical industries ltd european medicines agency ema accepts fremanezumab marketing...</i>

1.4. Elección de Campos de Texto

Los campos de texto disponibles son `title` (título del artículo) y `article` (cuerpo del artículo). La Tabla 3 resume las ventajas y desventajas de cada opción.

Tabla 3: Comparación de campos de texto para clasificación

Campo	Ventajas	Desventajas
<code>article</code>	Vocabulario rico y estadísticamente robusto; captura el estilo editorial completo	Mayor longitud implica mayor costo computacional; mayor presencia de ruido
<code>title</code>	Compacto y fácil de procesar; alta densidad informativa relativa	Muy corto (escasa señal estadística); mayor varianza por artículo
Combinación	Maximiza la información disponible	Puede generar desequilibrio si los títulos se repiten en proporción al cuerpo

Decisión: Para una futura tarea de clasificación, conviene utilizar principalmente el **cuerpo del artículo** (`article`), ya que contiene mayor cantidad de texto y, por lo tanto, mayor información potencial para capturar el estilo y contenido de cada medio de prensa.

Como posible extensión, también se podría considerar la generación de resúmenes del texto mediante un LLM, con el objetivo de reducir ruido y obtener representaciones más compactas del contenido.

1.5. Indicios que Identifican al Medio de Prensa

Para el conteo de identificadores de medios de prensa se utilizó tanto el texto original como las versiones preprocesadas:

- **Variantes del nombre** en el cuerpo del artículo limpio (`clean_text_article`) y en el título limpio (`clean_text_title`): se buscan las formas más comunes con las que cada medio aparece referenciado (ej. “reuters”, “new york times”, “nytimes”, “nyt”).
- **Dominio URL** en el texto crudo (`article`): se usa el texto sin limpiar porque `clean_text` elimina los puntos y barras que forman parte de las URLs (ej. `reuters.com`, `https://www.thehill.com`).

Un artículo se considera con auto-mención si contiene al menos uno de estos identificadores. Los resultados se presentan en la Tabla 4.

Tabla 4: Artículos con al menos una auto-mención del medio de prensa

Publicación	Total artículos	Con auto-mención	Porcentaje (%)
The Hill	2.349	2.349	100,0
Reuters	9.431	8.362	88,7
People	1.528	1.047	68,5
The New York Times	2.840	995	35,0
CNBC	2.623	909	34,7

Observaciones

- **The Hill** presenta el identificador más fuerte del corpus (100 %). Esto se debe a que queda el token `thehill` en todos los títulos del medio.
- **Reuters** (88,7 %) muestra una alta tasa de auto-mención debido a la estructura de dateline “[Ciudad] (Reuters) –”, presente en la mayoría de los artículos.
- **People** (68,5 %) constituye el caso más problemático, ya que el nombre del medio es una palabra de uso común. Por lo tanto, parte de estas coincidencias corresponden a falsos positivos y no a referencias explícitas al medio.
- **The New York Times** (35,0 %) y **CNBC** (34,7 %) presentan una presencia moderada, principalmente a través de menciones explícitas en el cuerpo del artículo.

Decisión sobre las pistas

Se recomienda enmascarar explícitamente los identificadores de medio detectados (`cnbc`, `reuters`, `thehill`, etc.) antes de entrenar un clasificador, reemplazándolos por un token neutro (`[PUBLICATION]`), con el objetivo de evitar que el modelo aprenda atajos basados en auto-menciones.

En el caso de **The Hill**, también es necesario enmascarar los tokens derivados de dominios en títulos, ya que aparecen de forma altamente sistemática.

Para **People**, un enmascaramiento directo puede eliminar vocabulario legítimo del idioma, por lo que se recomienda un enfoque más cuidadoso, por ejemplo mediante reglas basadas en contexto.

1.6. Restricción por Sección o Período Temporal

Restricción por sección temática

La restricción por sección presenta limitaciones importantes que dificultan su aplicación directa.

El principal obstáculo es estructural: cada medio define su propia taxonomía, con niveles de granularidad y criterios de clasificación distintos. **The Hill** carece completamente de datos en esta columna, lo que lo excluye de cualquier filtrado por sección sin etiquetado previo. **People**, por su parte, cubre exclusivamente entretenimiento (tv, cine, moda, celebridades), un dominio temático sin solapamiento con el resto de los medios del top 5. Una alternativa sería clasificar previamente los medios según su orientación temática general, lo que podría automatizarse mediante scraping o un agente que consulte información sobre cada publicación y agregue una columna de categoría editorial al dataset.

En el caso de **Reuters** y **CNBC**, por ejemplo, existe cierto potencial para una agrupación temática parcial. Hay solapamiento en cobertura financiera y económica (“Market News”, “Business News” en Reuters; “Markets”, “Market Insider” en **CNBC**), así como en política (“Politics” en **CNBC**; “us”, “world” en **NYT**). Una normalización manual de estas categorías permitiría construir macrocategorías como *Economía/Finanzas* o *Política*, dentro de las cuales comparar el estilo editorial de los medios con datos disponibles.

No obstante, este proceso implica un trabajo manual no trivial: requiere revisar y mapear decenas de etiquetas por medio, resolver ambigüedades y aceptar que el resultado sería

válido únicamente para los medios con sección informada.

Restricción por período temporal

Restringir el corpus a una ventana temporal común permite mitigar el impacto de eventos históricos específicos y cambios editoriales a lo largo del tiempo. A partir del análisis exploratorio, se observa una ventana de cobertura compartida aproximada entre **2016-01 y 2019-12** para los medios del top 5 (26.360 artículos), y una ventana entre **2017-05 y 2018-08** para todos los medios del dataset (9.120 artículos).

No obstante, una restricción temporal demasiado estricta puede reducir el tamaño del corpus y afectar la representatividad de ciertos medios, especialmente aquellos con menor volumen o cobertura irregular.

Conclusión: restringir por sección no es viable de forma directa: The Hill no tiene datos en esa columna, cada medio usa su propia taxonomía y People no comparte temática con los demás. Podría funcionar con un mapeo manual de categorías, pero implica un esfuerzo significativo y el resultado solo cubriría los medios con sección informada.

En contraste, la restricción temporal es más directa: basta con definir un rango de fechas común a todos los medios para obtener un subconjunto comparable sin depender de atributos faltantes o inconsistentes.

2. Conteo de Palabras y Visualizaciones

2.1. Palabras más Frecuentes por Medio

Se analizaron las frecuencias de palabras para cada uno de los cinco medios mediante dos visualizaciones complementarias: un ranking de las palabras más frecuentes por medio (Figuras 4 y 5) y nubes de palabras de artículos por fuente (Figura 6).




Figura 4: Palabras más frecuentes (NY Times, Reuters, The Hill), excluyendo stopwords.




Figura 5: Palabras más frecuentes (CNBC, People), excluyendo stopwords.




Figura 6: Nubes de palabras de artículos limpios por medio de prensa.

Se identifica un problema que surge por la presencia de términos genéricos del periodismo en inglés (“said”, “new”, “year”, “say”, “will”), que dominan el top de casi todos los

medios, lo que dificulta identificar diferencias a partir de frecuencias brutas. Adicionalmente, tokens residuales como “u”, “s” (provenientes de “U.S.”) y `hill`, `reuters` y `people` contaminan los rankings.

Observaciones

- **Reuters**: vocabulario técnico y conciso, con predominio de términos financieros y nombres de empresas, consistente con su modelo de agencia de noticias.
- **The New York Times** y **CNBC**: vocabulario político y económico con mayor diversidad léxica.
- **The Hill**: cobertura política intensa, con términos asociados al Congreso y la administración.
- **People**: vocabulario claramente diferenciado del resto, con términos propios del entretenimiento y la cultura popular.

Propuestas de mejora

1. **Métricas de exclusividad relativa en lugar de frecuencia bruta**: ponderar las palabras no solo por qué tan frecuentes son dentro de un medio, sino también por qué tan exclusivas resultan respecto a los demás, de modo de resaltar términos discriminativos en lugar de los más frecuentes en general..
2. **Secuencias de palabras contiguas**: considerar combinaciones de dos o más palabras consecutivas como una sola unidad de análisis, lo que permite capturar frases características como “capitol hill” o “new york times” que se pierden al contar palabras de forma aislada.
3. **Filtro de tokens residuales**: eliminar tokens de uno o dos caracteres y dominios de medios antes del análisis de frecuencias.
4. **Evolución temporal**: analizar cómo varía el vocabulario a lo largo del tiempo para detectar cambios de agenda editorial o convergencia entre medios durante eventos de alta carga noticiosa.

2.2. Medios con Mayor Cantidad de Palabras

La Tabla 5 resume las estadísticas de longitud de los artículos para cada uno de los cinco medios.

Tabla 5: Estadísticas de longitud de artículos por medio de prensa

Publicación	Media	Mediana	Total palabras
The New York Times	914	856	2.595.988
The Hill	570	456	1.337.790
CNBC	455	399	1.193.241
People	416	370	635.409
Reuters	266	183	2.512.726




Figura 7: Izquierda: total de palabras por medio. Derecha: distribución de la longitud de artículos por medio (sin outliers).

Observaciones

- **Reuters y The New York Times** acumulan totales de palabras similares ($\sim 2.5M$ cada uno), pero por razones opuestas: Reuters produce el triple de artículos que NYT, mientras que NYT produce los artículos más extensos (mediana: 856 palabras). Este contraste ilustra que el total de palabras mezcla efecto de volumen y longitud individual; para cualquier modelado posterior, la mediana por artículo es más informativa que el total acumulado.
- **Reuters** presenta la distribución más asimétrica: su mediana (183 palabras) está muy por debajo de su media (266), lo que refleja su modelo de *briefs* cortos de agencia conviviendo con artículos de análisis de mayor extensión.
- La diferencia de longitud entre medios puede sesgar modelos basados en conteos absolutos. Trabajar con frecuencias relativas (normalizadas por la longitud de cada artículo) mitiga este desequilibrio, ya que permite comparar documentos de distinta extensión en igualdad de condiciones.

2.3. Matriz de Menciones entre Medios

Se construyó una matriz 5×5 donde la entrada (i, j) representa la cantidad de veces que el medio i menciona al medio j en el texto limpio. Para la búsqueda se utilizaron los nombres en minúsculas: *reuters*, *new york times*, *cnbc*, *the hill*, y *people*.

Tabla 6: Matriz de menciones entre medios. Fila i : medio que menciona. Columna j : medio mencionado.

	Reuters	N.Y. Times	CNBC	The Hill	People
Reuters	—	41	44	7	2.856
The New York Times	54	—	19	45	4.769
CNBC	1.203	61	—	8	1.830
The Hill	123	190	20	—	2.023
People	7	51	5	13	—




Figura 8: Heatmap de la matriz de menciones entre medios (fila = fuente, columna = mencionado).

Observaciones

- **Reuters** es el medio más mencionado por los demás (especialmente por CNBC con 1.203 menciones), lo que es coherente con su rol de agencia de noticias internacional que provee material de fuente primaria.
- La columna de **People** registra cifras artificialmente altas (2.856–4.769) porque el término “people” es una palabra común del inglés (ej. “people said”, “many people”). Estas cifras no son comparables con las del resto de la tabla y deben interpretarse con cautela.
- **The New York Times** es activamente citado por The Hill (190 menciones), reflejo del rol de referencia que NYT tiene en el periodismo político estadounidense.
- **People** menciona muy poco a otros medios (máximo 51 a NYT), lo que es esperable para una revista de entretenimiento con escasa vocación de cobertura mediática.

Limitación metodológica

El conteo simple de ocurrencias de un término puede generar falsos positivos para nombres de medios que coinciden con palabras comunes (“people”) o partes de nombres de lugares (“the hill” puede aparecer en contextos geográficos). Para mejorar la precisión se podría recurrir a técnicas que identifiquen cuándo una palabra funciona efectivamente como nombre propio de una organización dentro del texto, distinguiéndola de su uso como




Figura 9: Grafo dirigido de menciones. El color de cada flecha corresponde al medio de origen; el grosor es proporcional al logaritmo de la cantidad de menciones.

sustantivo común. Otra alternativa es buscar el nombre del medio acompañado de contexto que confirme la referencia (ej. “according to Reuters”, “reported by The Hill”).

2.4. Preguntas Propuestas

Se proponen tres preguntas que podrían responderse a partir de este dataset:

Pregunta 1: ¿Es posible clasificar el medio de prensa a partir del vocabulario cuando se eliminan las pistas directas de autoría?

La tarea de clasificación pierde valor si el modelo aprende únicamente a detectar el nombre del medio en el texto (ej. la firma de dateline de Reuters). La pregunta es: ¿qué tan alta es la performance de clasificación cuando se eliminan todas las menciones explícitas de los nombres de medios?

Camino propuesto:

1. Crear una versión del dataset con los nombres de medios enmascarados.
2. Construir representaciones numéricas del texto que ponderen las palabras según su frecuencia dentro de cada artículo y su exclusividad respecto al resto del corpus, normalizadas por la longitud del documento.
3. Entrenar un clasificador (Naive Bayes, Regresión Logística).

4. Comparar las métricas (precisión, *recall*, F1) con y sin enmascaramiento. Una caída significativa en *performance* indicaría que el modelo dependía de las pistas directas.

Pregunta 2: ¿Difiere el estilo de escritura entre medios dentro de la misma sección temática?

El clasificador puede estar aprendiendo diferencias de *tema* (Reuters cubre finanzas, People cubre entretenimiento) en lugar de diferencias de *estilo*. Si restringimos el análisis a artículos etiquetados en la misma sección (ej. “Politics” o “Business”), ¿sigue siendo posible distinguir el medio con alta precisión?

Camino propuesto:

1. Seleccionar una sección con suficiente representación en todos los medios.
2. Aplicar el mismo *pipeline* de clasificación.
3. Analizar qué rasgos léxicos o estilísticos resultan más discriminativos dentro de esa sección, por ejemplo inspeccionando qué palabras reciben mayor peso en el modelo entrenado.

Pregunta 3: ¿Cómo evoluciona el vocabulario de cobertura de cada medio durante eventos de alta relevancia?

Los medios pueden converger o divergir en su vocabulario cuando cubren el mismo evento de gran impacto (elecciones, crisis económicas, etc.). La cuantificación de esta divergencia puede revelar diferencias en los enfoques editoriales.

Camino propuesto:

1. Identificar ventanas temporales alrededor de eventos clave (ej. elecciones de medio término de noviembre 2018).
2. Calcular, dentro de esa ventana, las palabras más distintivas de cada medio mediante alguna métrica que compare qué tan asociada está cada palabra a un medio frente a los demás, ajustando por la rareza general del término para no sobreponderar palabras poco frecuentes.
3. Comparar los resultados con un período de baja carga noticiosa equivalente para distinguir el vocabulario propio del evento del estilo editorial estable de cada medio.
4. Visualizar la evolución mediante un gráfico de *ranking* de palabras a lo largo del tiempo, que permita mostrar de forma compacta cómo cambian las posiciones relativas de los términos más distintivos.

3. Conclusiones

En esta tarea se exploraron y preprocesaron 30.213 artículos de 26 medios de prensa anglosajones, trabajando en profundidad con los cinco medios de mayor volumen (Reuters, The New York Times, CNBC, The Hill y People).

Los hallazgos principales son:

1. **Calidad de datos:** las columnas con mayor proporción de datos faltantes son `author` (38 %) y `section` (34 %). Los artículos sin cuerpo de texto (4 %) deben excluirse antes de cualquier análisis posterior.
2. **Desbalance de clases:** Reuters concentra el 31 % del dataset, más del triple que el segundo medio (NYT). Un clasificador deberá contemplar técnicas de balanceo o métricas ponderadas.
3. **Pistas de autoría:** The Hill y Reuters presentan tokens altamente identificables en el texto limpio (100 % y 88,7 % respectivamente). Enmascarar estos identificadores antes de clasificar es recomendable para evitar que el modelo aprenda atajos triviales.
4. **Longitud de artículos:** NYT produce artículos casi cuatro veces más extensos que Reuters en promedio. Trabajar con frecuencias relativas —normalizadas por la longitud de cada artículo— mitiga el efecto de esta diferencia en modelos basados en conteos, al poner a los documentos en igualdad de condiciones independientemente de su extensión.
5. **Vocabulario:** las palabras más frecuentes son en gran medida compartidas entre medios. Para identificar términos discriminativos, será necesario recurrir a métricas que ponderen no solo qué tan común es una palabra dentro de un medio, sino también qué tan exclusiva resulta respecto a los demás: términos que aparecen con alta frecuencia en una fuente pero son raros o ausentes en las otras son los que mejor capturan el vocabulario propio de cada medio.

Nota sobre el uso de asistentes de IA

La redacción de este informe y el código de análisis fueron desarrollados con la asistencia de Claude (Anthropic). Las decisiones metodológicas, la interpretación de los resultados y la revisión final del contenido son responsabilidad de las autoras.