

Introducción a la Ciencia de Datos
Maestría en Ciencia de Datos y Aprendizaje Automático

Tarea 2: Representación de Texto y Clasificación de Medios de Prensa

Integrantes
CASTROMAN, Nicole
ROMERO, Valeria

24 de junio de 2026

Índice

1. Introducción	2
2. Dataset y representación numérica de texto	2
2.1. Preparación del dataset	2
2.2. Verificación del balance de clases	2
2.3. Representación <i>Bag of Words</i>	3
2.4. Representación TF-IDF y n-gramas	3
2.5. Visualización con PCA	4
3. Entrenamiento y evaluación de modelos	5
3.1. Multinomial Naive Bayes	5
3.2. Validación cruzada y búsqueda de hiperparámetros	6
3.3. Entrenamiento final con el mejor modelo	7
3.4. Modelo alternativo: Regresión Logística	8
3.5. Cambio de medio de prensa	8
3.6. Técnica alternativa de extracción de <i>features</i>	9
3.7. Clasificación a nivel de título	10
4. Conclusiones	10

1. Introducción

En esta tarea se continúa con el conjunto de datos *All The News 2.1*¹ utilizado en la Tarea 1, que reúne artículos de noticias publicados en distintos medios de prensa anglosajones, pero el objetivo ahora es distinto, ya que en lugar de explorar y limpiar los datos se busca construir representaciones numéricas del texto y entrenar modelos que sean capaces de predecir a qué medio de prensa pertenece cada artículo a partir únicamente de su contenido. Para ello se trabaja con los tres medios que tienen mayor cantidad de artículos, se transforma el texto a una representación de tipo *bag of words* y TF-IDF, se visualiza el espacio resultante mediante PCA y finalmente se entrenan y comparan distintos clasificadores. El código completo se encuentra disponible en <https://github.com/usuario/Tarea-2-IntroCD>.²

2. Dataset y representación numérica de texto

2.1. Preparación del dataset

Se restringió el conjunto a los tres medios con mayor cantidad de artículos, que resultaron ser *Reuters*, *The New York Times* y *CNBC*, y luego de descartar los registros sin cuerpo de texto se obtuvo un subconjunto de 14,660 artículos. Sobre la columna `article` se aplicó la misma función `clean_text()` desarrollada en la Tarea 1, que elimina la primera línea del texto (donde suele aparecer el *dateline* editorial), convierte todo a minúsculas, unifica las variantes tipográficas del apóstrofo, elimina los signos de puntuación y los dígitos, y por último colapsa los espacios en blanco, de manera que el texto queda preparado para ser tokenizado por palabras.

Para poder evaluar los modelos sobre datos no vistos se partitionaron los datos en un conjunto de entrenamiento del 70% y uno de test del 30%, utilizando el parámetro `stratify` de `train_test_split` para realizar un muestreo estratificado y fijando `random_state` en 42 con el fin de obtener resultados reproducibles. De esta forma el conjunto de entrenamiento quedó con 10,262 artículos y el de test con 4,398.

2.2. Verificación del balance de clases

El muestreo estratificado garantiza que la proporción de artículos de cada medio se mantenga prácticamente idéntica en ambos conjuntos, lo cual puede verificarse en la Figura 1, donde se observa que *Reuters* concentra alrededor del 63% de los artículos mientras que *The New York Times* y *CNBC* aportan aproximadamente un 19% y un 18% respectivamente, y que las diferencias entre train y test son menores a una décima de punto porcentual. Cabe destacar desde ya que este reparto no es balanceado, debido a que *Reuters* tiene más del triple de artículos que cualquiera de los otros dos medios, lo que va a tener consecuencias importantes a la hora de interpretar las métricas de los modelos.

¹Versión muestreada provista por la cátedra, disponible en <https://huggingface.co/datasets/tomas-gr/all-the-news-2-1-Component-one-sampled>.

²Reemplazar por la URL definitiva del repositorio.




Figura 1: Proporción de artículos de cada medio en los conjuntos de entrenamiento y test. El muestreo estratificado conserva el balance entre ambas particiones.

2.3. Representación *Bag of Words*

La técnica de *bag of words* consiste en construir un vocabulario con todas las palabras distintas que aparecen en el corpus de entrenamiento y representar cada documento como un vector cuya posición j contiene la cantidad de veces que la palabra j aparece en ese documento, de modo que se descarta por completo el orden de las palabras y solo se conserva la información de frecuencia. Al aplicar `CountVectorizer` sobre el conjunto de entrenamiento se obtuvo una matriz de tamaño $10,262 \times 83,566$, es decir un documento por fila y una palabra del vocabulario por columna.

Esta matriz es de tipo *sparse* (rala) porque la enorme mayoría de sus entradas son cero, ya que cada artículo utiliza apenas unos cientos de palabras distintas del vocabulario total de más de ochenta mil términos, y de hecho en este caso solo el 0,25% de las entradas es distinto de cero. La conveniencia de almacenar únicamente los valores no nulos se vuelve evidente si se piensa en la memoria que requeriría la versión densa, dado que una matriz de $10,262 \times 83,566$ valores de tipo `float64` ocuparía aproximadamente 6,86 GB de RAM solo para el conjunto de entrenamiento de tres medios, cuando en realidad los valores no nulos son apenas algo más de dos millones; si se trabajara con el dataset completo y sin reducir la cantidad de medios el problema sería directamente inabordable en una máquina común, por lo que la representación rala no es una optimización opcional sino una necesidad.

2.4. Representación TF-IDF y n-gramas

Un *n-grama* es una secuencia contigua de n palabras dentro del texto, de manera que los unigramas corresponden a palabras individuales mientras que los bigramas son pares de palabras consecutivas como “new york” o “white house”, lo que permite capturar parte del contexto local que la representación de palabras sueltas pierde, a costa de aumentar considerablemente el tamaño del vocabulario.

Sobre la misma base se calculó la representación *Term Frequency – Inverse Document Frequency* (TF-IDF), que parte del conteo de palabras pero lo pondera de forma que se reduzca el peso de los términos muy frecuentes y se aumente el de los términos más característicos. La idea es que una palabra que aparece en casi todos los documentos (como los artículos o preposiciones) aporta poca información para distinguir un medio de otro, por lo que su peso debe ser bajo, mientras que una palabra que aparece mucho en un documento pero en pocos documentos del

corpus resulta muy discriminativa y debe recibir un peso alto; esto se logra multiplicando la frecuencia del término en el documento (TF) por el logaritmo de la inversa de la cantidad de documentos en que aparece (IDF), y luego se normaliza cada vector para que documentos de distinta longitud sean comparables. La matriz resultante tiene el mismo tamaño que la de *bag of words* pero sus valores ya no son conteos enteros sino pesos reales.

2.5. Visualización con PCA

Para poder visualizar en dos dimensiones un espacio que originalmente tiene decenas de miles de columnas se aplicó PCA sobre los vectores de TF-IDF, conservando las dos primeras componentes principales. Como PCA requiere trabajar con una matriz densa y densificar el vocabulario completo es inviable por la cantidad de memoria que implica, se acotó el vocabulario a las 5,000 palabras más frecuentes, lo que permite obtener la proyección sin agotar la RAM y manteniendo de todas formas los términos más relevantes. En la Figura 2 se comparan cuatro configuraciones del `TfidfVectorizer` que van agregando opciones de manera incremental.




Figura 2: Proyección de los artículos de entrenamiento sobre las dos primeras componentes principales del TF-IDF, para distintas configuraciones del vectorizador. Entre paréntesis se indica la varianza explicada por las dos componentes en cada caso.

En la configuración base, sin filtrar *stop words* y sin la ponderación IDF, las dos componentes explican un 19,6% de la varianza, pero esa cifra es engañosa ya que la estructura está dominada por las palabras vacías más comunes y no por el contenido propio de cada medio, y al activar el filtrado de `stop_words` en inglés la varianza explicada cae al 6,0% porque se eliminan justamente

esas palabras de altísima frecuencia que concentraban la mayor parte de la variación. Al agregar `use_idf=True` la varianza de las dos componentes baja todavía más, hasta un 3,1%, lo que tiene sentido porque la ponderación reparte el peso entre muchos términos discriminativos en lugar de concentrarlo en unos pocos, y la incorporación de bigramas con `ngram_range=(1,2)` no cambia demasiado el panorama. En todas las configuraciones puede verse que *Reuters* tiende a separarse del resto y a desplegarse a lo largo de la primera componente, mientras que *The New York Times* y *CNBC* se superponen en buena medida en una misma región, lo que ya anticipa que estos dos medios van a ser más difíciles de distinguir entre sí.

La respuesta a si los medios pueden separarse usando solamente dos componentes es claramente negativa, y la Figura 3 lo confirma al mostrar que incluso utilizando hasta diez componentes la varianza explicada acumulada apenas llega al 7,8%, lo cual es esperable en datos de texto, ya que la información se encuentra repartida entre miles de dimensiones y no existe un puñado de direcciones que concentren la mayor parte de la variación, a diferencia de lo que ocurre con datos de naturaleza más continua.




Figura 3: Varianza explicada individual y acumulada en función de la cantidad de componentes principales. Con diez componentes apenas se alcanza un 7,8% de varianza explicada.

En cuanto al origen de la separación que sí se observa, la misma parece responder a una combinación de diferencias temáticas y de estilo editorial más que a pistas explícitas del medio, debido a que la función de limpieza ya elimina la primera línea del texto donde figuraba el *dateline* de agencia y por lo tanto el nombre del medio no debería estar presente de forma directa; *Reuters* se distingue porque es una agencia de noticias que produce despachos breves con un vocabulario muy marcado de finanzas y temas internacionales, mientras que *The New York Times* y *CNBC* comparten un registro y una temática de negocios y política más parecidos entre sí, lo que explica que se confundan con mayor facilidad.

3. Entrenamiento y evaluación de modelos

3.1. Multinomial Naive Bayes

Como primer modelo se entrenó un *Multinomial Naive Bayes* sobre la representación TF-IDF con filtrado de *stop words*, ya que se trata de un clasificador clásico y muy utilizado para texto que asume independencia entre las palabras dado el medio y resulta económico de entrenar. Con la configuración por defecto se obtuvo una *accuracy* de 72,8% sobre el conjunto de test, valor que a primera vista podría parecer razonable pero que esconde un comportamiento muy pobre, tal como se aprecia en la matriz de confusión de la Figura 4.




Figura 4: Matriz de confusión del modelo Naive Bayes con parámetros por defecto. Prácticamente todos los artículos de CNBC son asignados a Reuters.

Lo que muestra la matriz es que el modelo clasifica correctamente casi la totalidad de los artículos de *Reuters* pero asigna a ese mismo medio la mayoría de los artículos de *CNBC*, de modo que el *recall* de *CNBC* es de apenas 0,02 a pesar de que su *precision* es de 1,00, mientras que *The New York Times* alcanza un *recall* de 0,49. La relación entre estos valores y la matriz de confusión es directa, dado que el *recall* de un medio se obtiene dividiendo los aciertos de ese medio (la celda de la diagonal) entre el total de artículos que realmente le pertenecen (la suma de su fila), por lo que un *recall* tan bajo indica que casi ninguno de sus artículos fue recuperado, en tanto que la *precision* se calcula sobre la suma de la columna y resulta alta porque las pocas veces que el modelo predice *CNBC* acierta.

Este resultado ilustra muy bien el problema de mirar únicamente la *accuracy*, ya que como *Reuters* representa por sí solo más del 60% de los datos, un modelo que prácticamente siempre predice *Reuters* consigue una *accuracy* alta sin haber aprendido a reconocer a los medios minoritarios, y si el desbalance entre medios fuera todavía mayor este efecto se agravaría hasta el punto de que la *accuracy* podría acercarse a la proporción de la clase mayoritaria sin ningún valor real, motivo por el cual conviene complementarla siempre con métricas por clase como *precision* y *recall* o con promedios macro que tratan a todas las clases por igual.

3.2. Validación cruzada y búsqueda de hiperparámetros

La validación cruzada (*cross-validation*) es una técnica que permite estimar el desempeño de un modelo de forma más robusta que con una única partición, y consiste en dividir el conjunto de entrenamiento en k partes o *folds*, entrenar el modelo k veces utilizando en cada iteración $k - 1$ folds para entrenar y el fold restante para validar, e ir rotando cuál es el fold de validación, de manera que al final cada dato fue usado para validar exactamente una vez y se obtienen k estimaciones de la métrica cuyo promedio y variabilidad resultan mucho más confiables que un único valor, ya que se reduce la dependencia respecto de una partición particular que pudo haber resultado favorable o desfavorable por azar.

Sobre esa base se implementó una búsqueda de hiperparámetros con **GridSearchCV** y validación cruzada de cinco folds, explorando el rango de n -gramas (unigramas frente a unigramas más bigramas) y el parámetro de suavizado **alpha** del Naive Bayes. En la Figura 5 se muestra mediante gráficos de violín la distribución de la *accuracy* de cada configuración a lo largo de los

cinco *splits*, lo que permite comparar no solo el valor promedio sino también la variabilidad de cada modelo.




Figura 5: Distribución de la *accuracy* en los cinco folds de validación cruzada para cada configuración evaluada en la búsqueda de hiperparámetros.

Se observa con claridad que el valor de **alpha** es determinante, ya que las configuraciones con **alpha=0,01** obtienen sistemáticamente las mejores *accuracy* y a medida que aumenta el suavizado el desempeño empeora de forma pronunciada, lo cual se explica porque un **alpha** alto agrega demasiada masa de probabilidad a las palabras no observadas y termina diluyendo la señal de los términos discriminativos. La mejor combinación resultó ser **alpha=0,01** junto con **ngram_range=(1,2)**, alcanzando una *accuracy* promedio de validación cruzada del 84,6%, y además los violines de las mejores configuraciones son angostos, lo que indica que el desempeño es estable entre los distintos folds.

3.3. Entrenamiento final con el mejor modelo

Con la mejor combinación de hiperparámetros se volvió a entrenar el modelo sobre la totalidad del conjunto de entrenamiento, sin reservar datos para validación, y se evaluó sobre el conjunto de test, obteniéndose una *accuracy* del 85,6%, bastante por encima del 72,8% del modelo inicial. Más importante que la mejora en la *accuracy* global es la mejora en el tratamiento de las clases minoritarias, ya que el *recall* de *CNBC* pasó de 0,02 a 0,50 y el de *The New York Times* subió a 0,89, de modo que el modelo ya no se limita a predecir la clase mayoritaria sino que efectivamente distingue entre los tres medios, aunque *CNBC* sigue siendo el más difícil tal como anticipaba la visualización con PCA. La matriz de confusión correspondiente se muestra en el panel izquierdo de la Figura 6.

A pesar de los buenos resultados conviene tener presente las limitaciones de una representación basada en *bag of words* o TF-IDF, dado que al descartar por completo el orden de las palabras se pierde toda la información sintáctica y gran parte del significado, no se capturan relaciones de sinonimia ni de polisemia (palabras distintas con el mismo sentido se tratan como columnas independientes, y una misma palabra con sentidos distintos se trata como una sola), y el espacio resultante es de dimensión muy alta y disperso; los bigramas alivian apenas en parte el problema del contexto local pero a cambio multiplican el tamaño del vocabulario, por lo que para captar relaciones semánticas más profundas haría falta otro tipo de representación.

3.4. Modelo alternativo: Regresión Logística

Como modelo alternativo se entrenó una *Regresión Logística* sobre las mismas *features* de TF-IDF, que a diferencia del Naive Bayes no asume independencia entre las palabras sino que aprende un conjunto de pesos para cada clase y combina linealmente las *features* para luego pasar el resultado por una función *softmax* que entrega las probabilidades de cada medio, eligiendo finalmente el de mayor probabilidad. Este modelo obtuvo una *accuracy* del 90,1%, superando al Naive Bayes optimizado en todas las métricas, con un *recall* de *CNBC* de 0,62 y de *The New York Times* de 0,92, tal como puede verse al comparar los dos paneles de la Figura 6.




Figura 6: Matrices de confusión sobre el conjunto de test del Naive Bayes optimizado (izquierda) y de la Regresión Logística (derecha). Esta última reduce de forma apreciable las confusiones de *CNBC*.

La superioridad de la Regresión Logística es esperable, debido a que es un modelo discriminativo que ajusta directamente la frontera de decisión y maneja bien la presencia de *features* correlacionadas, algo que el supuesto de independencia del Naive Bayes no contempla, aunque tiene como contrapartida un costo de entrenamiento mayor; de todas formas en ambos modelos el medio que concentra la mayor cantidad de errores sigue siendo *CNBC*, que se confunde principalmente con *Reuters*, lo que vuelve a ser coherente con la superposición observada en la proyección de PCA.

3.5. Cambio de medio de prensa

Para analizar el efecto del balance de los datos se repitió el experimento reemplazando a *CNBC* por *People*, que es una revista de entretenimiento, de modo que el nuevo conjunto quedó formado por *Reuters*, *The New York Times* y *People*. Como puede verse en el panel izquierdo de la Figura 7, este reemplazo acentúa el desbalance, ya que *People* representa apenas un 11,2% del conjunto frente al 68,2% de *Reuters*, con lo cual la clase minoritaria es ahora más pequeña que antes.




Figura 7: Nuevo conjunto reemplazando CNBC por People. A la izquierda el balance de clases del conjunto de entrenamiento y a la derecha la matriz de confusión del Naive Bayes.

Lo interesante es que, a pesar de ser la clase más chica, *People* se clasifica bastante bien, con un *recall* de 0,85, y esto se debe a que su temática de entretenimiento es muy distinta de la de los otros dos medios y por lo tanto su vocabulario resulta fácilmente separable, algo que ya se intuía en el mapeo de PCA donde un medio de temática tan diferente tiende a formar su propio grupo; de hecho la *accuracy* global trepa al 90,7% justamente porque al ser *People* tan distinta se reducen las confusiones, y el problema más serio pasa a estar entre *Reuters* y *The New York Times*, cuya *precision* cae a 0,75. Esto muestra que el desbalance por sí solo no condena a la clase minoritaria si esta es temáticamente distinguible, pero sí infla la *accuracy* a través de la clase mayoritaria y pone en riesgo el *recall* de las clases pequeñas cuando además se parecen entre sí. Para mitigar los efectos del desbalance existen técnicas como el sobre-muestreo de la clase minoritaria (ya sea replicando ejemplos o generando ejemplos sintéticos con métodos del tipo SMOTE) y el submuestreo de la clase mayoritaria (descartando parte de sus ejemplos), así como la posibilidad de asignar pesos a las clases en la función de costo, aunque en este trabajo no se implementaron.

3.6. Técnica alternativa de extracción de *features*

Una alternativa a las representaciones basadas en conteos como *bag of words* y TF-IDF son los *word embeddings*, como *Word2Vec* o *GloVe*, que representan a cada palabra mediante un vector denso de dimensión relativamente baja (por ejemplo unos pocos cientos de componentes) aprendido a partir de los contextos en los que la palabra aparece, de manera que palabras con significados parecidos terminan ubicadas en posiciones cercanas del espacio y se capturan así relaciones de similitud semántica que TF-IDF no puede representar, ya que para esta última dos sinónimos son simplemente dos columnas sin ninguna relación. Para representar un artículo completo se puede promediar los vectores de sus palabras, o bien recurrir a modelos contextuales más modernos como BERT, que asignan a cada palabra un vector distinto según el contexto de la oración. Cabría esperar que este tipo de representación mejore especialmente la distinción entre medios de estilo y temática parecidos, como *The New York Times* y *CNBC*, ya que aporta información semántica que va más allá de la coincidencia exacta de palabras, aunque a cambio requiere modelos preentrenados y un mayor costo computacional, y no siempre supera a TF-IDF cuando la diferencia entre clases es sobre todo de vocabulario.

3.7. Clasificación a nivel de título

Por último, de forma opcional se repitió la clasificación con los tres medios originales pero utilizando únicamente el título del artículo en lugar de su cuerpo completo. En este caso la *accuracy* del mejor modelo Naive Bayes descendió al 71,5%, lo cual es razonable debido a que un título tiene apenas unas pocas palabras y por lo tanto ofrece muchísima menos señal que un artículo completo de varios cientos de palabras, de modo que la matriz de confusión vuelve a deteriorarse y *CNBC* cae a un *recall* de 0,34 mientras que *Reuters*, por ser el medio más característico y más numeroso, sigue siendo el más fácil de reconocer con un *recall* de 0,89. Esto confirma que la cantidad de texto disponible por documento es un factor clave para la calidad de la clasificación.

4. Conclusiones

A lo largo del trabajo se construyeron representaciones numéricas del texto mediante *bag of words* y TF-IDF y se comprobó la necesidad de utilizar matrices ralas debido al enorme tamaño y la dispersión del vocabulario, y mediante PCA se observó que los medios no son separables en pocas dimensiones, ya que la información se reparte entre miles de direcciones, aunque de todas formas se distingue que *Reuters* se aparta del resto mientras que *The New York Times* y *CNBC* se superponen. En la etapa de modelado quedó en evidencia que la *accuracy* por sí sola puede ser engañosa frente a clases desbalanceadas, tal como mostró el primer Naive Bayes que prácticamente ignoraba a *CNBC*, y que ajustar los hiperparámetros mediante validación cruzada mejora de manera importante el reconocimiento de las clases minoritarias, llevando la *accuracy* del 72,8% al 85,6%. La Regresión Logística resultó ser el mejor de los modelos probados, con una *accuracy* del 90,1%, y el experimento de cambio de medio mostró que una clase minoritaria pero temáticamente distinta como *People* puede clasificarse sin problemas, de modo que la dificultad real no proviene tanto del desbalance en sí mismo como de la similitud temática y estilística entre los medios.